

2026年度 中間研究報告

3Dシーンにおける位置関係を扱う検索 — 総括・今後の計画 —


Kenichiro Goto, 2026-08-03

Table of Contents


1. Table of Contents
2. 研究テーマ
3. 年度ロードマップ
4. OV-Segの改良
5. 03・LangSplatとは
6. 04・SAM3で2D教師を作る
7. 05・言語特徴を3D Gaussianへ蒸留する
8. 06・LangSplatの追試 (1/2)
9. 07・LangSplatの追試 (2/2)
10. 08・公開checkpointの評価
11. 09・位置関係クエリ
12. 10・LangSplat + Rel3D
13. 11・Rel3Dへ渡す18次元特徴
14. 12・夏季休暇の計画

研究テーマ

"coffee next to the apple" のように、位置関係を含む言語クエリで3Dシーンを検索する



query: coffee next to the apple




query: glass next to the apple

- 現行の relevancy は物体・単語単位の類似度のため、どちらのクエリも赤点が `apple` へ集まる。
- → 位置関係を「構造」として扱う仕組みが必要。

年度ロードマップ


完了した研究工程

2026年4月～7月・完了済みの工程のみ



今後の研究計画

2026年8月1日～12月31日




8月1日から実装・実験・検証を続け、11月1日から12月31日まで論文を執筆する。

OV-Segの改良

OV-Seg

OV-Seg 再現結果


ADE20K-150 検証データ・2026年4月



既存研究の報告値を再現した結果。

OVSAM3 手法置換の比較

ADE20K-150 検証データ・mIoU



SAM3は参考値。OV-SegとOVSAM3は本研究で評価。

OVSAM3はR-101構成を上回ったが、SAM3の参考値には届かなかった。

03・LangSplatとは

3D Gaussian Splattingの各Gaussianに、CLIP由来の言語特徴を追加する。




Figure 2. The framework of our LangSplat. Our LangSplat leverages SAM to learn hierarchical semantics to address the point ambiguity issue. Then segment masks are sent to the CLIP image encoder to extract the corresponding CLIP embeddings. We learn an autoencoder with these obtained CLIP embeddings. Our 3D language Gaussian learn language features on the scene-specific latent space to reduce the memory cost. During querying, the rendered language embeddings are sent to the decoder to recover the features on the CLIP space.

境界を作る

3次元へ蒸留する

文章で検索する

SAMのwhole / part / subpartマ
スクで画素ごとの意味を限定

同じ物体を複数視点で観測し、
Gaussianへ言語特徴を学習

レンダリングした特徴をCLIP空間
へ戻し、テキストとの類似度を計算

04・SAM3で2D教師を作る

Multi-view images → SAM3 masks → CLIP features → 2D teacher map

SAM3を使う位置

階層を保つための処理

`preprocess` のマスク生成部を、論文のSAMからSAM3へ置換する。3Dモデル内部ではなく、学習前の教師作成に使う

論文の `subpart / part / whole` を維持するには、SAM3の出力を3階層へ対応付ける後処理が必要になる

論文 Eq. (1): 画素 v の教師特徴

$$\mathbf{L}_t^l(v) = V(\mathbf{I}_t \odot \mathbf{M}^l(v)), \quad l \in \{s, p, w\}$$

V : CLIP image encoder、 M : 対象画素が属するマスク、 l : 意味階層

05・言語特徴を3D Gaussianへ蒸留する

1. 論文 Eq. (4): RGBと同じalpha blendingで言語特徴をレンダリング

$$\mathbf{F}^l(v) = \sum_{i \in \mathcal{N}} \mathbf{f}_i^l \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j)$$

2. 論文 Eq. (6): レンダリング結果を、圧縮した2D教師へ合わせる

$$\mathcal{L}_{lang} = \sum_{l \in \{s, p, w\}} \sum_{t=1}^T d_{lang}(\mathbf{F}_t^l(v), \mathbf{H}_t^l(v))$$

512次元のCLIP特徴は、シーン固有autoencoderで3次元の H へ圧縮する。

コア: 2Dで得た「この領域は何か」という特徴を、複数視点で整合する3D Gaussianの属性として学習する。検索はGaussian間の関係ではなく、各点のテキスト類似度で行う。

06・LangSplatの追試 (1/2)


RGB 3DGS 学習損失

完了済みrunのみ・総損失・対数尺度・2026年8月2日取得



RGB 3DGS 再構成品質

完了済み実行の最終PSNR・30,000ステップ



RGB 3DGS · training loss


RGB 3DGS · final PSNR

完了3シーンでは、waldo kitchenが最小の最終lossと最大PSNR 32.99 dBを示した。

07・LangSplatの追試 (2/2)

オートエンコーダ 学習損失

完了済みrunのみ・総損失・対数尺度・2026年8月2日取得



Language Gaussian 学習損失

完了済みrunのみ・総損失・対数尺度・2026年8月2日取得



Scene-wise autoencoder · loss

Language Gaussian · loss

圧縮器と3D言語特徴の両段階でlossが低下し、学習パイプラインが動作することを確認した。

08・公開checkpointの評価


apple



coffee



bag of cookies



LERF-OVS・teatime (mask threshold = 0.4)

mIoU

Localization Accuracy


論文との比較

0.6503


0.8814

teatimeの報告値65.1%、88.1%とほぼ一致

09・位置関係クエリ



coffee next to the apple



glass next to the apple

$$r(q) = \min_i \frac{\exp(\phi_{img} \cdot \phi_{qry})}{\exp(\phi_{img} \cdot \phi_{qry}) + \exp(\phi_{img} \cdot \phi_{canon}^i)}$$

単一の画像特徴と文章全体の類似度なので、subject・relation・anchorの構造を区別できない。

10 · LangSplat + Rel3D

物体検索と関係判定を分離し、候補ペアをRel3Dで再順位付けする。

Query parse → LangSplat × 2 → Geometry → Rel3D MLP → Render

Parse

q = (coffee, next to,
apple)

Retrieve

subjectとanchorを別々に検
索


Classify

candidate pair → relation
probability

$$p(r \mid s, a) = \text{softmax}(g_{\theta}([\mathbf{f}_s, \mathbf{f}_a]))$$

LangSplatは「どこに何があるか」、Rel3Dは「2物体がどの関係にあるか」を担当する。

11・Rel3Dへ渡す18次元特徴



Rel3D, Figure 6: aligned feature で学習したMLPの成功例と失敗例

各物体を中心・回転・大きさの9次元で表し、subjectとanchorを連結する。

$$\mathbf{f}_{obj} = (x, y, z, \alpha, \beta, \gamma, w, h, d) \in \mathbb{R}^9, \quad \mathbf{x} = [\mathbf{f}_{subject}, \mathbf{f}_{anchor}] \in \mathbb{R}^{18}$$

LangSplat側

relevancy上位Gaussianをクラスタ化し、重心・bbox寸法・姿勢を推定


Adapter側

座標系をそろえて18次元化する。中心差3次元だけでは入力形式にならない

12・夏季休暇の計画


夏期計画：8月開始分

2026年8月3日～9月6日・すべて予定



夏期計画：9月開始分

2026年9月7日～30日・すべて予定



再現実験を閉じた後、18次元adapter、Rel3D、クエリパーサー、統合評価へ進む。

まとめ

LangSplatの再現を基盤に、「物体検索」と「関係判定」を分離した構成を評価する。

- 完了: OV-Seg 再現（論文値一致）、OVSAM3 評価、LangSplat 環境構築と公開 checkpoint の再現、DagsHub / MLflow 追跡、LERF-OVS データ整備
 - 進行中: 五シーン再現パイプライン
 - 8月1日～10月31日: 18次元adapter → Rel3D ベースライン → クエリパーサー → 統合 → 実験・検証
 - 11月1日～12月31日: 論文執筆・修正
1. ov-seg — OV-Seg reproduction and SAM3 replacement
 2. 3dgs-relationship-recognition — LangSplat reproduction and relation pipeline
 3. LERF-OVS dataset (Hugging Face)
 4. decks — this presentation and seminar materials